补充材料

基于心肺运动试验汇总指标的老年高血压患者运动安全分层框架

TODO: 作者姓名

2026 年 4 月

目录

S1. 方法学细节与前期方法比较 **2**
S1.1 变量角色分类详细定义 2
S1.2 条件分位参考模型技术细节 2
S1.3 表型负担评分技术细节 3
S1.4 置信度权重来源 3
S1.5 方法学质量标准 3

S2. 结局锚点验证模型细节 **4**
S2.1 结局锚点验证模型完整细节 4
S2.2 分析框架输出结构 4

S3. 替代权重与敏感性分析 **4**
S3.1 置信度权重替代方案 4
S3.2 前期方法对照 5

S4. Mahalanobis 异常表型审计与全量输出摘要 **5**
S4.1 分析框架全量输出摘要 5
S4.2 机器学习辅助验证结果 5
S4.3 Mahalanobis 异常表型审计详细结果 6

S5. 稳健性分析 **6**
S5.1 严格 vs 宽松参考子集对比 6
S5.2 分层稳健性 6
S5.3 多定义一致性分析 7

S1. 方法学细节与前期方法比较

S1.1 变量角色分类详细定义

本框架中所有 CPET 变量严格按以下四类分配，防止概念混淆（表 S1）：

表 S1: 变量角色分类

角色类型	变量	域/层	用途
表型变量（Reserve 域）	VO_2peak	Reserve	负担评分
	无氧阈 VO_2	Reserve	负担评分
	O_2 脉搏峰值	Reserve	负担评分
	峰值 METs	Reserve	负担评分
表型变量（Ventilatory 域）	V_E/V_{CO_2} slope	Ventilatory	负担评分
	OUES	Ventilatory	负担评分
不稳定变量	EHT 状态	Instability	覆盖规则（严重）
	峰值收缩压	Instability	覆盖规则（严重/轻度）
	峰值舒张压	Instability	覆盖规则（严重）
	O_2 脉搏轨迹（代理）	Instability	覆盖规则（严重）
置信度辅助变量	峰值 HR% 预测值	Effort	努力程度代理
	VO_2peak% 预测值	Anchor	锚点一致性
验证变量	临床结局替代指标	Validation	外部锚定验证（仅）
	队列编码	Validation	队列识别
对照参考变量	前期连续评分等	对照	仅前期方法对照

临床结局替代指标在最终安全分层确定后方可使用，严禁用于定义分层边界。

S1.2 条件分位参考模型技术细节

模型架构：采用线性分位数回归（pinball loss 最小化）。特征工程：自然三次样条基函数（K=5 个内部节点，度数 3）处理年龄的连续非线性效应；哑变量（独热编码）分别处理性别（男/女）和运动方案（踏车/平板），未知类别采用零编码处理。正则化参数设置以防止小样本严格参考子集的过拟合。

单调性约束：对每个样本，五个分位数预测值经排序处理，保证 $\hat{Q}_{0.10} \leq \hat{Q}_{0.25} \leq \hat{Q}_{0.50} \leq \hat{Q}_{0.75} \leq \hat{Q}_{0.90}$ 严格成立。

分位模型评估：在宽松参考子集上验证分位数校准，检验 q10 实际覆盖率 ≈10%、q90 实际覆盖率 ≈90%。

目标变量：6 个核心表型变量分别独立拟合分位模型，各变量的分位参考束分别保存，在全量数据上独立预测个性化参考值。

S1.3 表型负担评分技术细节

变量级负担转换规则：详细定义参见正文表 2（表型变量负担转换规则）。各变量方向（越高越好/越低越好）、三级负担切点（q10/q25/q75/q90）及缺失处理规则均已在正文方法节完整列出，此处不再重复。以下补充内容聚焦于实现细节：

缺失值处理：字段缺失时该变量负担记 NaN，域内均值以可用字段平均（忽略缺失）；若 Reserve 域可用字段 <2 或 Ventilatory 域可用字段 <1，则对应域评分记缺失，综合表型负担 P_{lab} 可能为缺失。

表型分层切点：以严格参考子集上 P_{lab} 分布的 P75 和 P90 为切点，两点均由参考子集自动估计；若切点退化（P75=P90），则 P90 替换为 P75+ϵ（0.001）以避免空区间。

S1.4 置信度权重来源

置信度引擎四分量权重（0.25/0.20/0.25/0.30）基于以下方法学先验（表 S2）：

表 S2: 置信度分量权重说明

分量	含义	权重	理由
$C_{\text{completeness}}$	核心字段完整率	0.25	数据质量基础，与其他分量平衡
C_{effort}	努力程度（HR%pred）	0.20	反映努力程度对安全评估的重要性
C_{anchor}	外部-内部参考一致	0.25	参考锚点验证
$C_{\text{validation}}$	与结局三分位一致	0.30	结局验证为主要驱动，权重最高

权重来自方法学先验，未经前瞻性数据校准；置信度阈值：≥0.80 高、0.65–0.80 中、<0.65 低。低置信度 + 无严重不稳定 → 不确定层。未来研究应以前瞻性标注队列（含真实结局）校准各分量权重。

S1.5 方法学质量标准

分析框架的方法学质量评估基于以下预设标准（表 S3）：

表 S3: 方法学质量标准与判定逻辑

指标	阈值	判定级别	说明
参考子集高危比例	$< 15\%$	不满足时为不合格	参考合理性
参考子集低危比例	$> 50\%$	不满足时为部分满足	参考合理性
最终分层 vs 临床结局替代指标梯度	方向正确（低危 < 中危 < 高危）	方向反转为不合格	结构效度
	非单调但非反向	部分满足	结构效度
高置信度比例	$\geq 10\%$	低于时为部分满足	置信度分布
综合判定：存在不合格条件 → 不满足；仅部分满足 → 部分满足；否则 → 满足预设标准			

S2. 结局锚点验证模型细节

S2.1 结局锚点验证模型完整细节

结局锚点验证模型（ElasticNet Logistic, solver=SAGA, L1-ratio=0.5）以全量 CPET 变量（排除验证变量）预测临床结局替代指标二元结局，采用嵌套 5 折交叉验证。

模型性能：交叉验证 AUC 0.564（±0.016）；测试集 AUC 0.608；AUPRC 0.203；Brier Score 0.125；校准良好（截距约 0，斜率约 1）。

定位说明：结局锚点验证器不定义分层边界，仅提供结局风险三分位输入置信度引擎，并验证最终安全分层的结构效度方向。AUC 处于 CPET 汇总指标信息量合理范围（0.55–0.65）内，证实最终安全分层与临床结局替代指标方向一致。LightGBM 敏感性分析结果方向与 ElasticNet 一致（均在 0.55–0.65 范围内）。

S2.2 分析框架输出结构

本分析框架为每位受试者生成以下核心分析输出（表 S4）：

表 S4: 分析框架主要输出变量

输出变量类别	主要内容	用途
表型负担评分	Reserve 域均值负担、Ventilatory 域均值负担、综合 P_{lab}	表型分层
表型负担分层	低危/中危/高危（基于 P_{lab} 分位切点）	初步分层
不稳定信号	严重不稳定标志、轻度不稳定标志	覆盖规则
覆盖后分层	置信度校正前安全分层（含覆盖效应）	中间步骤
置信度评分	综合置信度 C（0–1）、置信度标签（高/中/低）	不确定性量化
最终安全分层	低危/中危/高危/不确定层（含覆盖与置信校正）	主要输出
结局锚点验证	结局风险预测概率、风险三分位（低/中/高）	结构效度验证
异常审计	Mahalanobis 距离、异常标志（仅用于数据质控）	质控

S3. 替代权重与敏感性分析

S3.1 置信度权重替代方案

当前置信度权重（0.25/0.20/0.25/0.30；完整度/努力/锚点一致/结局一致）基于方法学先验。以下替代权重方案用于稳健性检验：

- **等权方案**：四分量等权（0.25/0.25/0.25/0.25）；高置信度比例预计偏低（结局一致性权重降低）。
- **完整度优先方案**：完整度权重提升至 0.60，其余等比分配；高置信度比例在字段完整队列中预计升高。

- **无结局分量方案**：结局一致性权重设为 0，其余三分量等比重新分配；适用于无临床结局替代指标的独立外部队列。

置信度阈值敏感性（SA-3）：高置信度比例对阈值敏感（阈值 0.70 时 71.4%，0.75 时 39.3%，0.80 时 33.0%，0.85 时 31.5%），但梯度方向在所有阈值变体下保持正向单调，方法学质量标准稳健。

S3.2 前期方法对照

表 S5: 前期评分方案与本框架对照

维度	前期评分方案	本框架
核心评分	等权三轴连续评分（0–100）	表型负担评分（P_{lab}，0–1）
参考方程	OLS（年龄 + 性别 +BMI）	条件分位（年龄样条 + 性别 + 方案
不稳定处理	混合于连续评分中	独立覆盖规则（严重/轻度分级）
临床结局替代指标角色	外部验证	外部验证（边界更清晰）
不确定性输出	无（强制三分类）	明确不确定层（低置信度非严重样本
置信度机制	无	四分量加权置信度（阈值 ≥0.80）
机器学习验证	P0/P1 预测模型（AUC 0.58，F1 0.47–0.50）	作为对照参考保留
异常审计	独立 Mahalanobis 模型（未纳入方法学）	Robust MinCovDet，定位数据质控
方法学质量标准	无明确预设标准	三项量化标准（满足/部分满足/不满

本框架设计的关键改进：概念分离、参考精细化、不确定性明确化。前期方法的对照结果（P0 AUC=0.583，P1 F1=0.499，结局模型 AUC=0.548）保存供对照参考，不参与本框架主要结论。

S4. Mahalanobis 异常表型审计与全量输出摘要

S4.1 分析框架全量输出摘要

以下各项来源于本框架在全量真实数据（N=3,232）上的运行结果（表 S6）：

S4.2 机器学习辅助验证结果

以下结果来自前期方法论验证，保留供方法学对照参考，不参与本框架主要结论。

运动前风险预测(P0)：XGBoost(无峰值血压特征)AUC=0.583，交叉验证 AUC=0.623±0.028；两变量临床基线(HTN+BMI)AUC=0.611 > 机器学习全特征(AUC=0.583)，反映 CPET 汇总指标的预测性能上限。

运动后安全区分类 (P1)：CatBoost $F1_{\mathrm{macro}}$=0.499，κ=0.302；低危召回 67.1%，中危召回 51.8%，高危召回 30.8%。代理泄漏消融分析：全特征 vs 无氧峰值特征 ΔF1=+0.003（可忽略），证实预测性能上限来自特征集固有局限，而非泄漏驱动。

表 S6: 分析框架全量输出摘要（N=3,232）

指标	值	说明
总样本数	3,232	全量分析样本（含标记保留样本）
严格参考子集 N	903（27.9%）	CTRL 组 + 严格筛选标准
参考子集低危比例	69.2%	满足 >50% 方法学质量标准
参考子集高危比例	10.2%	满足 <15% 方法学质量标准
严重不稳定触发 N（%）	220（6.8%）	不稳定覆盖致高危
表型负担致高危 N（%）	741（22.9%）	表型负担分层高危
最终分层：低危	19.7%	含覆盖与置信度校正
最终分层：中危	25.6%	
最终分层：高危	29.7%	
不确定层比例	24.9%（805 例）	低置信度（$C < 0.65$）+ 无严重不稳定
高置信度比例	33.0%	$C \geq 0.80$
临床结局替代指标梯度方向	严格单调正向	低危 14.0%，中危 15.1%，高危 18.0%
结局模型交叉验证 AUC	0.564（±0.016）	测试集 AUC=0.608，AUPRC=0.203
方法学质量综合评估	满足预设标准	三项预设标准全部满足
置信度权重	0.25/0.20/0.25/0.30	完整度/努力/锚点/结局

结局锚定模型（前期方法）：交叉验证 AUC=0.578±0.031，测试集 AUC=0.548；高危区阳性率（25.3%）> 中危区（10.5%）> 低危区（5.1%）呈单调梯度，在本框架结局锚点验证中得到复现，验证了最终安全分层对临床结局替代指标的结构效度方向。

S4.3 Mahalanobis 异常表型审计详细结果

审计切点：经验切点 P75=3.825，P95=8.788；参考子集 N=969；Mahalanobis 距离与临床结局替代指标的相关系数 $r=-0.011$（方向性弱）。

本框架定位：Robust Mahalanobis 距离（MinCovDet，$\chi^2_{k,0.975}$ 阈值）仅用于输入数据的质控审计（识别数据录入错误和异常表型样本，建议优先进行数据录入核查），**不参与最终安全分层定义**。异常标志阳性 654 例（20.2%）应在数据录入核查中优先处理。

S5. 稳健性分析

S5.1 严格 vs 宽松参考子集对比

严格参考子集（N=903）vs 宽松参考子集（N=969）稳健性检验：两个参考子集定义下最终安全分层的梯度方向一致（均为正向单调），主要分析采用严格参考子集（N=903，27.9%）；详细分位数校准验证结果见本框架相关分析报告。

S5.2 分层稳健性

按以下维度分层的方法学质量标准一致性：

- 性别（男/女）
- 年龄（<67 岁 / ≥67 岁）
- 方案（踏车 / 平板）
- 血压字段完整性（bp 完整 / 缺失）
- 无血压信息敏感性（排除峰值血压相关覆盖规则）

分层验证结果：最终安全分层（全量样本，N=3,232）及高置信度子集（N=1,065）均呈正向单调梯度（满足预设标准）。值得注意的是，单独使用表型负担分层时梯度方向发生反转，说明不稳定性覆盖规则是实现结构效度的必要机制。各分层中参考子集低危 >50%、高危 <15% 的方法学质量标准均满足。

S5.3 多定义一致性分析

多定义投票分析（K=4 种分层定义）：高信度 841 例（26.2%），不确定区 2,391 例（74.0%，含 33 例分类异常样本），低危/高危冲突 1,974 例（61.6%）；全样本 N=3,232。高信度高危阳性率（28.6%）> 低危（5.1%），证实高信度分层具有临床区分度。

本框架的置信度引擎在架构上整合了多定义一致性框架的核心精神：以四分量加权置信度（字段完整度、努力程度、锚点一致、结局一致）替代 K 定义投票，提供连续置信度分数而非二元高/低信度标签，从而实现更精细的不确定性量化。